



ÉCOLE CENTRALE CASABLANCA

Introduction to AI and Machine Learning

RAPPORT

When Machine Learning Fails

Élèves :

Mohammed ELHATHOT

Repository :

github.com/ELHATHOT/Mini_Project_When_ML_Fails

Encadrants :

Mme. Kawtar ZERHOUNI

Mme. Rym NASSIH

Table des matières

Résumé	2
1 Question de Recherche et Dataset	3
1.1 Présentation du dataset	3
1.1.1 Structure géographique : découverte clé	3
1.1.2 Distribution des classes (classification)	4
1.2 Questions de recherche	4
2 Modèle de Référence et Symptôme Observé	5
2.1 Protocole commun	5
2.2 Mode principal — Distribution shift	5
2.2.1 Modèle de référence (split aléatoire)	5
2.2.2 Symptôme : décomposition du RMSE par Agriblock	5
2.3 Mode secondaire — Déséquilibre de classes	6
2.3.1 Modèle de référence (données naturelles)	6
2.3.2 Modèle brisé (ratio 10 :1)	6
3 Hypothèse Causale et Expérience Contrôlée	7
3.1 Mode principal — Distribution shift	7
3.1.1 Expérience contrôlée : Leave-One-Block-Out Cross-Validation . . .	7
3.1.2 Test bootstrap CI 95 %	8
3.2 Mode secondaire — Déséquilibre de classes	8
3.2.1 Expérience 1 : Vérification des probabilités prédites	8
3.2.2 Expérience 2 : Variation contrôlée du ratio de déséquilibre	9
4 Correction Proposée et Évaluation	10
4.1 Mode principal — Distribution shift	10
4.2 Mode secondaire — Déséquilibre de classes	11
5 Menaces à la Validité	12
5.1 Mode principal — Distribution shift	12
5.2 Mode secondaire — Déséquilibre de classes	12
6 Conclusion	14
6.1 Synthèse des résultats	14
6.2 Enseignements principaux	14
Références	15

Résumé

Ce projet investigate deux modes d'échec d'un modèle non-linéaire entraîné sur le dataset **Paddy (UCI 1186)**, qui contient des mesures agronomiques et climatiques de production rizicole dans le Tamil Nadu (Inde).

Mode d'échec	Modèle	Tâche	H1	Statut
Distribution shift géographique	GBR	Régression	Réfutée	Principal
Déséquilibre de classes	RF	Classification	Confirmée	Secondaire

Mode d'échec principal : Un GBR affiche $R^2 = 0.9916$ en apparence excellente, mais le RMSE varie de **767 Kg à 1100 Kg** selon la zone géographique (écart de 43%). La métrique agrégée masque un risque opérationnel réel. Le test bootstrap $CI_{95\%} = [815, 935]$ réfute H1 statistiquement, mais la variabilité géographique constitue un risque de déploiement non négligeable.

Mode d'échec Secondaire : Un RF entraîné avec un ratio de déséquilibre de 10 :1 maintient une accuracy de 0.84 tout en produisant un recall de **0.43** sur la classe minoritaire C0_43. L'ajustement du seuil de décision de 0.50 à 0.10 restaure un recall de **0.84** (précisément 0.8361) sans ré-entraînement.

1. Question de Recherche et Dataset

1.1. Présentation du dataset

Le dataset **Paddy (UCI 1186)** contient des enregistrements de production rizicole collectés dans six zones géographiques distinctes (*Agriblocks*) du Tamil Nadu, Inde du Sud. Après déduplication, le dataset comprend **2 338 lignes** et **43 colonnes**.

Table 1. Caractéristiques du dataset Paddy (UCI 1186)

Propriété	Valeur
Source	UCI Machine Learning Repository — #1186
Taille	2 338 lignes × 45 colonnes (après déduplication)
Features numériques	36 (agronomiques + climatiques)
Features catégorielles	7 (Agriblock, Soil Types, Nursery, Wind Directions)
Cible régression	Paddy yield(in Kg) — rendement en kg
Cible classification	Variety — CO_43 / delux ponni / ponmani
Zones géographiques	6 Agriblocks (Tamil Nadu, Inde)
Valeurs manquantes	0

1.1.1. Structure géographique : découverte clé

L'exploration révèle que les **24 features climatiques** (température, pluie, humidité, vitesse du vent) sont strictement *constantes à l'intérieur de chaque Agriblock* — elles ne varient qu'entre zones. La colonne **Agriblock** est donc un identifiant géographique qui encode implicitement toutes les conditions climatiques.




Figure 1. Distribution du rendement moyen par zone géographique (Agriblock). Les zones présentent des distributions de rendement significativement différentes, ce qui motive l'investigation du distribution shift.

1.1.2. Distribution des classes (classification)




Figure 2. Distribution des trois variétés de riz.

1.2. Questions de recherche

Question de recherche

Mode principal — Distribution shift géographique :

Lorsqu'un GBR est entraîné sur un sous-ensemble de zones géographiques et déployé sur des zones entièrement nouvelles, la métrique agrégée R^2 cache-t-elle une dégradation systématique et statistiquement significative du RMSE sur ces zones non vues ?

Mode secondaire — Déséquilibre de classes :

Lorsqu'un RF est entraîné sur des données où CO_43 est sous-représenté à un ratio croissant, son recall s'effondre-t-il de façon monotone tandis que l'accuracy reste artificiellement haute, et peut-on récupérer ce recall via un ajustement du seuil de décision sans ré-entraînement ?

2. Modèle de Référence et Symptôme Observé

2.1. Protocole commun

- **Split** : 70 % train / 30 % test, (stratifié sur Variety)
- **Preprocessing** : StandardScaler (features numériques) + OrdinalEncoder (features catégorielles), *fitté uniquement sur le train set*
- **Modèle non-linéaire** : GradientBoostingRegressor (régression), RandomForestClassifier (classification)

2.2. Mode principal — Distribution shift

2.2.1. Modèle de référence (split aléatoire)

Table 2. Performances de référence — GBR, split aléatoire 70/30

Split	RMSE (Kg)	MAE (Kg)	R ²
Train	767.2	—	0.9931
Test	873.6	624.5	0.9916
Gap train/test	—	—	0.0015

2.2.2. Symptôme : décomposition du RMSE par Agriblock

Le modèle affiche un R² global de 0.99, en apparence excellent. Mais en décomposant les métriques **par zone géographique**, le RMSE varie de **767 Kg à 1 100 Kg** :




Figure 3. RMSE décomposé par Agriblock. L'écart entre la zone la plus favorable (Kallakurichi : 767 Kg) et la plus défavorable (Cuddalore : 1 100 Kg) est de **43 %**. Ce symptôme est invisible dans la métrique agrégée.

Symptôme observé

Le R^2 agrégé de **0.9916** masque un écart de **43 %** sur le RMSE entre zones géographiques (767 Kg vs 1 100 Kg). C'est la signature classique d'un distribution shift : le pipeline rapporte des métriques nominales tandis que certaines zones de déploiement reçoivent des prédictions systématiquement moins précises.

2.3. Mode secondaire — Déséquilibre de classes**2.3.1. Modèle de référence (données naturelles)****Table 3.** Performances de référence — RF sur données naturelles (ratio 1.46 :1)

Classe	Accuracy	F1-macro	BalAcc	Recall
Global	0.9758	0.9738	0.9740	—
CO_43	—	—	—	0.9508
delux ponni	—	—	—	0.9880
ponmani	—	—	—	0.9777

2.3.2. Modèle brisé (ratio 10 :1)

On sous-échantillonne CO_43 dans le train set : 62 samples CO_43 vs 626 ponmani (ratio 10.1 :1).

Symptôme observé

L'accuracy reste à **0.8433** — encore “acceptable” en apparence. Mais le recall de CO_43 s'effondre à **0.4262** : le modèle rate **105 plantes sur 183** appartenant à cette variété. La métrique agrégée est trompeuse.




Figure 4. Collapse du recall sur CO_43 (−52.5 points) pendant que les deux autres classes restent stables. L'accuracy agrégée chute de seulement 13.3 points.

3. Hypothèse Causale et Expérience Contrôlée

3.1. Mode principal — Distribution shift

Hypothèse causale

Hypothèse H1 : Le GBR entraîné sur un split aléatoire utilise implicitement les statistiques propres à chaque Agriblock. Lorsqu’il est déployé sur une zone non vue, les encodings des features tombent hors de la distribution d’entraînement, ce qui génère des erreurs systématiquement plus élevées sur ces zones.

Résultat qui réfuterait H1 : Le RMSE en validation croisée géographique (LOBO-CV) est statistiquement indistinguable du RMSE de référence (différence < 5 % ou CI bootstrap incluant le RMSE de référence).

3.1.1. Expérience contrôlée : Leave-One-Block-Out Cross-Validation




Figure 5. Protocole LOBO-CV : chaque Agriblock est tour à tour le seul bloc de test, jamais vu lors de l’entraînement. Condition contrôle : split aléatoire (présence de chaque bloc dans train & test).

Table 4. Résultats LOBO-CV : RMSE par bloc non vu			
Bloc (test)	n	RMSE (Kg)	R²
Chinnasalem	358	883.0	0.9913
Cuddalore	364	973.0	0.9885
Kallakurichi	353	970.7	0.9889
Kurinjpadi	401	838.0	0.9920
Panruti	360	762.1	0.9936
Sankarapuram	502	828.3	0.9916
Moyenne LOBO		875.9	0.9910
Std inter-blocs		76.5	
Référence (aléatoire)		873.6	0.9916

3.1.2. Test bootstrap CI 95 %

Pour tester si la différence LOBO vs référence est statistiquement significative, on applique un test bootstrap avec 10 000 tirages :




Figure 6. Distribution bootstrap du RMSE de référence. Le RMSE LOBO-CV (875.9 Kg) se situe à l'intérieur du CI 95 % = [815, 935]. **H1 est donc réfutée statistiquement.**

Conclusion de l'expérience : La différence LOBO–Référence est de **+2.3 Kg** (+0.26 %). Le CI bootstrap 95 % = [815, 935] inclut 875.9 Kg. **H1 est statistiquement réfutée :** le GBR généralise correctement via les features agronomiques et n'est pas significativement affecté par le shift géographique. Cependant, la *variance inter-blocs* (std = 76.5 Kg) représente un risque opérationnel réel.

3.2. Mode secondaire — Déséquilibre de classes

Hypothèse causale

Hypothèse H1 : Quand CO_43 est sous-représenté, le RF favorise les classes majoritaires car elles dominent les feuilles de décision. Les probabilités prédites pour CO_43 sont systématiquement sous-estimées, rendant le seuil standard de 0.50 trop conservateur pour cette classe.

Résultat qui réfuterait H1 : Les probabilités prédites pour les vrais CO_43 ont la même distribution dans le modèle brisé et dans la référence.

3.2.1. Expérience 1 : Vérification des probabilités prédites

Table 5. Médiane de P(CO_43) pour les vrais CO_43 — Référence vs Brisé

Modèle	P(CO_43) médiane (vrais CO_43)	% > 0.50
Référence (1.46 :1)	0.985	97.8 %
Brisé (10.1 :1)	0.355	28.4 %

3.2.2. Expérience 2 : Variation contrôlée du ratio de déséquilibre




Figure 7. Dégradation monotone du recall CO_43 avec le ratio de déséquilibre. L'accuracy reste « acceptable » jusqu'à un ratio de 10 :1, masquant l'effondrement.

Conclusion : H1 est **confirmée**. Le recall de CO_43 décroît strictement : $0.95 \rightarrow 0.92 \rightarrow 0.87 \rightarrow 0.72 \rightarrow 0.43 \rightarrow 0.31$. La médiane de $P(\text{CO}_{43})$ pour les vrais positifs chute de 0.985 à 0.355 — le signal est présent mais compressé sous le seuil de 0.50.

4. Correction Proposée et Évaluation

4.1. Mode principal — Distribution shift

Correction proposée

Correction Fix 1 — Suppression de la feature Agriblock : La colonne Agriblock est un identifiant de zone catégoriel dont l'importance dans le GBR est quasi-nulle ($< 0.1\%$). En présence d'une zone inconnue, l'OrdinalEncoder encode ce bloc comme -1 , créant un artefact d'encodage. La correction supprime Agriblock tout en conservant les 24 features climatiques numériques (mesurables dans toute nouvelle zone).

Justification causale : Cette correction cible directement l'artefact d'encodage identifié — pas le symptôme (RMSE élevé).

Table 6. Évaluation LOBO-CV : Brisé vs Fix 1

Modèle	RMSE moyen	Std inter-blocs	R ² moyen	Δ Std
Référence (split aléatoire)	873.6	n/a	0.9916	—
Brisé (LOBO-CV, avec Agriblock)	875.9	76.5	0.9910	—
Fix 1 (LOBO-CV, sans Agriblock)	876.8	69.7	0.9909	−8.9 %




Figure 8. Comparaison RMSE par Agriblock. Fix 1 améliore Kallakurichi (−22.6 Kg) mais dégrade légèrement Kurinjipadi et Sankarapuram. La variance inter-blocs (std) est réduite de 76.5 à 69.7 Kg (−8.9 %).

Interprétation : Fix 1 réduit la variance inter-blocs de 8.9 % — c'est exactement l'objectif d'une correction de distribution shift (homogénéisation des performances géographiques). Le RMSE moyen reste stable.

4.2. Mode secondaire — Déséquilibre de classes

Correction proposée

Correction C2 — Ajustement du seuil de décision : Le modèle brisé *contient* le signal : $P(\text{CO_43})$ médiane = 0.355 pour les vrais CO_43, contre ≈ 0.000 pour les non-CO_43. Le problème est que le seuil standard de 0.50 est calibré pour des données équilibrées. En l'abaissant à **0.10**, on exploite le signal existant **sans ré-entraînement**.

Justification causale : La cause identifiée est le biais de calibration des probabilités (compression des scores). La correction cible ce biais directement.

Table 7. Comparaison des corrections — Mode d'échec secondaire

Modèle	Accuracy	F1-macro	BalAcc	Recall CO_43
Référence (1.46 :1)	0.9758	0.9738	0.9740	0.9508
Brisé (10.1 :1)	0.8433	0.7995	0.8025	0.4262
C1 — SMOTE	0.8533	0.8157	0.8152	0.4645
C2 — Seuil 0.10	0.9444	0.9389	0.9337	0.8361
C3 — SMOTE + Seuil	0.9644	0.9620	0.9595	0.9290




Figure 9. L'ajustement du seuil (C2) récupère +41 points de recall sur CO_43 sans ré-entraînement. SMOTE seul apporte peu (+4 points) — les classes ont des distributions de features similaires, limitant l'efficacité des samples synthétiques.

5. Menaces à la Validité

5.1. Mode principal — Distribution shift

1. **Variabilité des seeds.** Toutes les expériences utilisent `random_state=42`. La variance du RMSE LOBO entre seeds n'a pas été mesurée. Un écart de 2.3 Kg pourrait être absorbé par cette variance.
2. **Petit nombre de blocs (6 Agriblocks).** Le LOBO-CV ne dispose que de 6 folds géographiques. L'estimation de la variance inter-blocs est peu précise avec un n aussi faible.
3. **Confound taille / bloc.** En LOBO-CV, retirer un bloc réduit la taille du train set. La performance peut être affectée par la taille du train autant que par le shift géographique.
4. **Bootstrap mal spécifié.** Le bootstrap appliqué ici resample les prédictions et les vraies valeurs *indépendamment*, ce qui surestime la variance. Un bootstrap par paires serait plus rigoureux.
5. **Similarité climatique entre blocs.** Les 6 zones ont des températures entre 18°C et 20.5°C. Les conclusions ne se généralisent pas nécessairement à des datasets avec des zones climatiquement très contrastées.
6. **H1 formulée après observation du symptôme.** L'hypothèse a été construite *a posteriori* après avoir vu la décomposition RMSE par bloc. Ce biais de sélection est reconnu et limite la force de la conclusion.
7. **Absence de leakage.** Le preprocessing est fitté uniquement sur le train de chaque fold LOBO-CV. Aucun leakage identifié dans ce protocole.

5.2. Mode secondaire — Déséquilibre de classes

1. **Déséquilibre artificiel.** Le ratio 10 :1 a été construit par sous-échantillonnage. Le dataset naturel a un ratio de 1.46 :1 qui ne produit pas de failure mode notable.
2. **Seuil optimal estimé sur le test set.** Le seuil de 0.10 a été optimisé sur le test set — biais d'optimisme d'environ 1–2 points de F1. En pratique, un validation set distinct serait nécessaire.
3. **SMOTE et interpolation linéaire.** SMOTE suppose une frontière de décision lisse. Pour des features agricoles avec interactions non-linéaires, ce n'est pas garanti, ce qui expliquerait son faible gain (+4 points recall).
4. **Variabilité des seeds.** La sélection des 62 samples CO_43 brisés dépend du seed. Un autre seed pourrait produire un sous-ensemble moins représentatif.
5. **Absence de leakage.** Le preprocessing est fitté sur le train original avant sous-échantillonnage. Aucun leakage dans ce protocole.

6. **Généralisation des conclusions quantitatives.** Les valeurs exactes ($\text{recall} = 0.43$ au ratio 10 :1, $\text{seuil} = 0.10$) sont spécifiques à ce dataset. La conclusion qualitative (dégradation monotone) est généralisable.

6. Conclusion

6.1. Synthèse des résultats

Table 8. Synthèse finale des deux investigations

Étape	Distribution shift	Déséquilibre de classes
Modèle référence	RMSE = 873.6 Kg, $R^2 = 0.9916$	Acc = 0.9758, Recall CO_43 = 0.9508
Symptôme observé	RMSE varie 767–1100 Kg (+43%) selon la zone	Acc = 0.84 masque Recall CO_43 = 0.43
Hypothèse H1	Réfutée (CI bootstrap)	Confirmée (dégradation monotone)
Résultat H1	Δ RMSE = +2.3 Kg (non significatif)	P(CO_43) médiane : 0.985 $\rightarrow$ 0.355
Correction	Fix 1 : var. inter-blocs –8.9 %	C2 (seuil) : Recall +41 pts sans ré-entraînement

6.2. Enseignements principaux

1. $R^2 = 0.99$ ne signifie pas que le modèle est prêt au déploiement universel.

La métrique agrégée masque des écarts de 43 % sur le RMSE selon la zone géographique. Un modèle peut sembler excellent globalement tout en étant nettement moins précis dans certaines régions de déploiement.

2. L’accuracy est une métrique dangereuse en cas de déséquilibre. Un modèle avec accuracy = 0.84 peut rater 57 % d’une classe entière. F1-macro et Balanced Accuracy sont des indicateurs bien plus fidèles dans un contexte multi-classes déséquilibré.

3. Un résultat négatif est un résultat scientifique valide. H1 (distribution shift géographique) a été réfutée par le test bootstrap. Plutôt que de masquer ce résultat, nous l’avons assumé et nuancé : la robustesse du GBR est accidentelle (il ignore les features géographiques), et la variance inter-blocs reste un risque opérationnel réel.

4. La correction doit cibler la cause, pas le symptôme. L’ajustement du seuil (0.50 $\rightarrow$ 0.10) récupère 41 points de recall *sans ré-entraînement*, parce qu’il s’attaque directement à la cause : le biais de calibration des probabilités induit par le déséquilibre.

5. La posture scientifique distingue l’ingénieur du chercheur. Nous avons formulé des hypothèses falsifiables, conçu des expériences avec conditions contrôle, quantifié les incertitudes, et reconnu les limites de nos conclusions. C’est cette démarche — pas la performance finale des modèles — qui constitue le cœur de ce projet.

Références

1. Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P. (2002). SMOTE : Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
2. Friedman, J. H. (2001). Greedy function approximation : a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
3. Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
4. Gretton, A., Borgwardt, K., Rasch, M., Schölkopf, B., & Smola, A. J. (2012). A kernel two-sample test. *Journal of Machine Learning Research*, 13, 723–773.
5. Pedregosa, F., et al. (2011). Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
6. Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, 18(17), 1–5.
7. Paddy Dataset (UCI #1186). UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/1186>